

CardioCare 종단간 머신러닝 시스템 구축

202121069 최한빈

1. 문제 정의와 사용 목적

CardioCare는 환자의 임상 데이터를 기반으로 심장병 발병 가능성을 예측하여 심장 전문의의 의사결정을 지원하는 머신러닝 시스템이다. 본 시스템의 목적은 의료진이 심장병 위험 환자를 조기에 식별할 수 있도록 보조 정보를 제공하는 것이다.

본 시스템은 의료 전문가를 대체하지 않는다. CardioCare의 예측 결과는 진단 보조 수단으로만 활용되며, 최종 진단과 치료 결정은 반드시 의료 전문가에 의해 이루어져야 한다. 따라서 본 시스템은 "결정(decide)"이 아닌 "정보 제공(inform)"을 목적으로 한다.


2. EDA 핵심 결과

데이터셋의 구조와 분포를 이해하기 위해 EDA(Exploratory Data Analysis)를 수행하였다.

2.1 Target 클래스 분포

Target 분포를 확인한 결과 정상 환자(target=0)와 심장병 환자(target=1)의 비율이 비교적 균형에 가까웠다. 그러나 완전히 동일한 비율은 아니므로 단순 Accuracy만으로 모델 성능을 평가할 경우 편향된 결과가 발생할 수 있다고 판단하였다.

따라서 본 프로젝트에서는 Accuracy뿐만 아니라 Balanced Accuracy, Precision, Recall, F1-Score를 함께 사용하였다.



2.2 변수 분포 분석

연속형 변수(age, trestbps, chol, thalach, oldpeak)의 분포를 확인하였다.


Age는 대체로 정규분포에 가까운 형태를 보였으며, 50~60세 구간에 데이터가 집중되어 있었다.

Trestbps(안정 시 혈압)는 대부분 110~150 범위에 분포하였으며 일부 높은 혈압 값을 가진 환자가 존재하였다.

Chol(콜레스테롤)은 대부분 180~300 범위에 분포하였으나 일부 매우 높은 값이 존재하였다.

Thalach(최대 심박수)는 비교적 넓은 범위에 분포하였으며 뚜렷한 왜도는 관찰되지 않았다.

Oldpeak는 0~2 구간에 데이터가 집중되어 있었으며 우측으로 긴 꼬리를 가진 분포를 보였다.



2.3 이상치 탐지


Boxplot을 이용하여 주요 연속형 변수의 이상치를 분석하였다.

분석 결과 다음과 같은 특징을 확인하였다.

- * trestbps에서 일부 높은 혈압 이상치 존재
- * chol에서 매우 높은 콜레스테롤 값 존재
- * oldpeak에서 일부 극단값 존재
- * age와 thalach에서는 상대적으로 이상치가 적음

다만 본 데이터는 의료 데이터이므로 이상치가 단순한 측정 오류가 아니라 실제 환자의 상태를 나타낼 가능성이 있다. 따라서 이상치를 무조건 제거하지 않고 모델 학습에 반영하였다.

대신 StandardScaler를 적용하여 극단값의 영향을 완화하였다.



2.4 EDA 결과 요약

EDA를 통해 일부 연속형 변수에서 이상치가 존재함을 확인하였다. 또한 Target 클래스가 완전히 균형적이지 않음을 확인하였다.

이에 따라 다음과 같은 전처리 전략을 적용하였다.

- * 중앙값 기반 결측값 처리
- * StandardScaler 적용
- * 입력값 범위 검증
- * 학습 데이터에 대해서만 전처리 fit 수행

이를 통해 데이터 누수를 방지하면서 새로운 데이터에도 동일하게 적용 가능한 전처리 파이프라인을 구축하였다.

3. EDA 결과에 근거한 전처리 결정

EDA 결과를 바탕으로 다음과 같은 전처리 전략을 적용하였다.

1. 결측값 처리
 - * 수치형 변수는 중앙값(median)으로 대체
 - * 범주형 변수는 최빈값(most frequent)으로 대체

2. 중복 데이터 제거
 - * 중복 행 제거 수행

3. 입력 범위 검증
 - * chol, age, trestbps 등 주요 임상 변수에 대해 허용 범위를 설정

4. 스케일링
 - * StandardScaler 사용

전처리는 sklearn Pipeline 및 ColumnTransformer를 사용하여 구현하였다. 이를 통해 학습 시 사용된 동일한 전처리를 추론 환경에서도 재사용할 수 있도록 하였다.

또한 데이터 누수를 방지하기 위해 모든 전처리 과정은 학습 데이터에 대해서만 fit을 수행하였다.

4. MLflow 실험 기반 모델 비교 및 최종 선택 정당화

본 프로젝트에서는 Logistic Regression, Support Vector Machine(SVC), Random Forest 총 세 가지 모델을 비교하였다. 또한 Random Forest에 대해 GridSearchCV를 사용한 하이퍼파라미터 탐색을 수행하였다.

Model	Balanced Accuracy	Precision	Recall	F1 Score
Logistic Regression	0.8734	0.8125	0.9286	0.8667
SVC	0.8198	0.7931	0.8214	0.8070
Random Forest	0.8225	0.7742	0.8571	0.8136
Random Forest (GridSearchCV)	0.8858	0.8621	0.8929	0.8772

실험 결과 GridSearchCV를 적용한 Random Forest가 가장 높은 Balanced Accuracy와 F1 Score를 기록하였다. 그러나 본 프로젝트에서는 심장병 예측이라는 의료 도메인의 특성을 고려하여 Recall을 가장 중요한 평가 지표로 선정하였다.

심장병 환자를 정상으로 분류하는 False Negative는 환자의 치료 기회를 놓치게 만들 수 있으며, 실제 의료 환경에서 매우 위험한 결과를 초래할 수 있다. 따라서 단순한 전체 정확도보다 환자를 놓치지 않는 능력이 더욱 중요하다고 판단하였다.

Logistic Regression은 Recall 0.9286으로 모든 모델 중 가장 높은 값을 기록하였다. 이는 실제 심장병 환자의 약 92.9%를 올바르게 탐지할 수 있음을 의미한다. 따라서 본 프로젝트에서는 Logistic Regression을 최종 모델로 선택하였다.

또한 Logistic Regression은 비교적 단순한 구조를 가지므로 모델 해석이 쉽고, 의료 전문가가 결과를 이해하기 용이하다는 장점도 존재한다.

5. 테스트와 패키징

프로젝트의 안정성을 확보하기 위해 unittest 기반의 테스트를 작성하였다.

구현된 테스트는 다음과 같다.

1. 예측 결과 shape 검증
2. 예측 확률 범위 검증
3. 임상 입력값 범위 검증
4. 동일 입력에 대한 결정론성 검증

또한 Docker를 사용하여 프로젝트를 컨테이너화하였다.

Docker 이미지는 requirements.txt를 기반으로 의존성을 설치하고, 학습된 모델을 로드하여 추론을 수행하도록 구성하였다.

이를 통해 다른 환경에서도 동일한 결과를 재현할 수 있도록 하였다.

6. 드리프트 결과 및 재학습 전략

모델 운영 환경을 가정하여 데이터 드리프트 탐지를 수행하였다.

연속형 변수 중 chol(혈중 콜레스테롤 수치)에 인위적인 분포 이동을 적용하였다. 이후 학습 데이터의 분포와 변경된 데이터의 분포를 Kolmogorov-Smirnov(KS) 검정을 통해 비교하였다.

실험 결과는 다음과 같다.

Feature	KS Statistic	p-value	Drift Detected
age	0.0876	0.8124	No
trestbps	0.1384	0.2762	No
chol	0.7329	< 0.0001	Yes
thalach	0.0706	0.9517	No
oldpeak	0.1462	0.2218	No

분석 결과 chol 변수에서 매우 작은 p-value가 관찰되었으며, 사전에 정의한 기준($p < 0.05$)에 따라 데이터 드리프트가 탐지되었다.

원본 데이터와 드리프트 데이터에서의 Balanced Accuracy는 다음과 같았다.

Dataset	Balanced Accuracy
Original Test Set	0.8734
Drifted Test Set	0.8734

이번 실험에서는 입력 데이터 분포의 변화가 탐지되었지만 모델 성능은 크게 감소하지 않았다. 이는 해당 모델이 일정 수준의 입력 변화에 대해 비교적 안정적으로 동작하고 있음을 의미한다.

그러나 실제 운영 환경에서는 드리프트가 누적될 경우 성능 저하로 이어질 가능성이 존재한다. 따라서 지속적인 모니터링이 필요하며, 특정 변수에서 반복적으로 드리프트가 탐지되는 경우 재학습을 수행해야 한다.

또한 재학습 과정에서는 의료 전문가의 검토(Human-in-the-loop)를 포함하여 잘못된 피드백 루프가 형성되지 않도록 관리해야 한다.

7. 서빙 방식 선택

본 프로젝트는 Model-as-a-Service(MaaS) 방식을 선택하였다.

그 이유는 다음과 같다.

- * 모델 업데이트가 용이.
- * 중앙 집중형 모니터링 가능.
- * 드리프트 탐지 후 빠른 재배포 가능.

반면 의료 데이터는 민감한 개인정보(PHI)를 포함할 수 있으므로 전송 과정의 암호화와 접근 통제가 필요하다.

8. 한계 및 윤리적 고려 사항

본 프로젝트는 공개 심장병 데이터셋을 기반으로 구축되었다. 따라서 실제 병원 환경의 다양한 환자군을 충분히 반영하지 못할 수 있다.

또한 특정 연령대나 인구 집단에 편향된 데이터가 포함될 경우 모델의 예측 결과 역시 편향될 수 있다.

CardioCare는 의료진의 의사결정을 보조하는 시스템이며 의료 전문가를 대체하지 않는다.
따라서 예측 결과만으로 진단을 내려서는 안 된다.

추가로 1주일의 개발 기간이 주어진다면 다음을 수행할 계획이다.

- * XGBoost 추가 실험
- * SHAP 기반 설명 가능성 분석
- * 실제 API 서버 구축
- * 자동 재학습 파이프라인 구축